

Détection et Réduction des Biais dans les Systèmes de Recrutement

Objectifs pédagogiques :

- Comprendre les différents types de biais dans les données et algorithmes
- Apprendre à mesurer et visualiser les biais
- Expérimenter des techniques de correction
- Analyser l'impact des biais sur les modèles de ML

PARTIE 1 : Analyse exploratoire des biais

1. Création du dataset biaisé

Implémentez un dataset synthétique de 2000 candidatures avec les features suivantes :

- Genre (Homme/Femme)
- Âge (20-30, 30-40, 40-50, 50+)
- Ville (Paris, Marseille, Lyon, Lille)
- Diplôme (A, B, C - A étant le meilleur)
- Embauche (0/1)

Intégrez des biais réalistes : sur-représentation masculine, discrimination par âge, avantage géographique pour Paris.

2. Visualisation des biais

Créez des visualisations pour mettre en évidence :

- Le taux d'embauche par genre
- Le taux d'embauche par tranche d'âge
- Le taux d'embauche par ville
- Le taux d'embauche par niveau de diplôme

Quels graphiques sont les plus pertinents pour chaque type de biais ? Justifiez.

3. Métriques d'inégalité

Calculez pour chaque feature :

- L'écart-type des taux d'embauche entre les catégories
- Le range global (max-min) des taux d'embauche

Quelle métrique vous semble la plus informative ? Pourquoi ?

PARTIE 2 : Correction des biais

4. Stratégie de correction

Proposez et implémentez une méthode pour réduire les biais identifiés. Votre méthode doit :

- Cibler spécifiquement les groupes défavorisés
- Préserver les relations méritocratiques (diplôme)
- Maintenir la cohérence globale du dataset

Expliquez les compromis de votre approche.

5. Évaluation de la correction

Comparez visuellement et statistiquement le dataset original et corrigé :

- Les distributions des features ont-elles changé ?
- Les taux d'embauche par groupe sont-ils plus équitables ?
- La corrélation diplôme→embauche est-elle préservée ?

6. Stockage et traçabilité

Sauvegardez les deux versions du dataset. Quelle importance accordez-vous à la conservation des données originales dans un processus de correction des biais ?

PARTIE 3 : Impact sur les modèles ML

7. Entraînement et évaluation

Entraînez un modèle de régression logistique sur :

- Le dataset original biaisé
- Le dataset corrigé

8. Analyse des performances différentielles

Pour chaque modèle, calculez l'accuracy globale et par :

- Genre
- Tranche d'âge
- Ville
- Niveau de diplôme

Lequel des deux modèles est le plus équitable ? Justifiez avec des métriques.

9. Biais algorithmiques

Créez une version biaisée de l'algorithme qui discrimine intentionnellement contre :

- Les femmes (20% de chance supplémentaire de rejet)
- Les seniors de 50+ (30% de chance supplémentaire de rejet)

Entraînez cet algorithme sur le dataset corrigé et analysez l'impact.

PARTIE 4 : Synthèse et recommandations

10. Analyse comparative finale

Réalisez une comparaison complète des trois scénarios :

1. Dataset biaisé + Algorithme neutre
2. Dataset corrigé + Algorithme neutre
3. Dataset corrigé + Algorithme biaisé

Quelles conclusions tirez-vous sur :

- L'importance relative des biais dans les données vs les algorithmes ?
- L'impact de la correction sur l'équité et la performance ?
- Les limites des approches de correction testées ?

11. Recommandations éthiques

Rédigez une note de synthèse à destination de l'entreprise avec :

- 3 recommandations pour détecter les biais
- 3 recommandations pour les corriger
- 3 bonnes pratiques pour monitorer l'équité en production